DISEÑO DE SISTEMA: SEUDONIMIZACIÓN Y RESOLUCIÓN DE ENTIDADES (KIPU PAY)

Objetivo: Anonimizar 1-a-1 el corpus multimodal (2.028 mensajes, 26 docs, 6.243 filas en 4 tablas) y operar /v1/anonymize sin fugas, conservando utilidad y consistencia.

Dann Arenas

1. ENTENDIMIENTO DEL PROBLEMA: SUPUESTOS, CASOS DIFÍCILES Y LÍMITES (FUERA DE ALCANCE)

1.1 Supuestos y Decisiones Base

- **S1 (Padrones Maestros como Ancla):** `clientes.csv` (Latin-1, `;`) y `empleados.xml` (+ `users.json`) traen IDs estables (CL−∗, KP−∗) que permiten construir el registro canónico antes de tocar texto libre.
- **S2 (Desempate en Fuentes Cruzadas):** La ciudad o cargo no aparecen junto al nombre en el chat; las homónimas se desempatan cruzando radicados (`pqrs.xml`), fecha y monto (`transacciones.csv`) o adjuntos.
- **S3 (El Juez es un Programa):** `validar.mjs` normaliza confusables, invisibles, tildes, separadores de dígitos y el prefijo 57. Nuestro guard es un port exacto y el validador corre dentro de `/v1/run` como compuerta, porque una salida inválida gasta la corrida sin puntaje.
- **S4 (Crecimiento Incremental):** El API sumará datos sin borrar los previos y el jurado compara `entities.json` antes y después. Un mapa persistido (`state/entity_ledger.json`) se carga antes de asignar; `HMAC(secret, canonical_id)` genera solo a las personas nuevas.
- **S5 (Disponibilidad):** Si el servicio deja de responder durante una corrida, la corrida se pierde: despliegue sin suspensión, con disco persistente, y `/run` en un proceso aparte para que `/health` siempre responda.

1.2 Casos Difíciles (Edge Cases)

- **Homonimia y Jerarquía:** 2 clientas con el mismo nombre completo, 1 agente que se llama igual que una clienta y relación `"reporta a"` entre empleados en `empleados.xml`.
- **Personas Fuera del Autor:** El bot dice el nombre completo del agente en el traspaso, los agentes repiten correos y celulares de clientes y el texto nombra a terceros; resolver solo por `user` filtra datos.
- **PII Ofuscada y Canales Ocultos:** Nombres en MAYÚSCULAS sin tildes en extractos, correos deletreados (*"arroba"*/*"punto"*), confusables e invisibles, metadatos PDF, comentarios HTML, 2 docs en inglés y nombres en `attachments.filename`.
- **Apellidos = Lugares/Marcas y Razones Sociales:** *"Sra. Restrepo"* se reemplaza, pero *"Barrio Restrepo"* o *"Seguros Bolívar"* se conservan. En *"Odontología María López SAS"* solo se seudonimiza el nombre propio.
- **Cuasi-identificadores:** Tuplas `(barrio, ocupación, año)` que señalan a una sola persona se generalizan en la unión de tabla y chat (ocupación → sector, barrio → ciudad, año → *"hace unos años"*).

1.3 Qué Dejamos Fuera y Por Qué

- **Reescritura de texto con LLM:** Se deja fuera porque altera datos de negocio, destruye la similitud del texto no personal y no es determinista entre corridas (la misma persona podría recibir nombres distintos).
- **Perturbar montos, fechas o llaves (`CL/TX/PQR`):** Se excluye porque romper las llaves foráneas o cifras financieras destruye las uniones entre tablas y el valor para entrenar soporte.
- **Privacidad diferencial formal (ε-DP):** Descartada porque aplica a agregados estadísticos y rompe la entrega 1-a-1 registro por registro.
- **Reversibilidad para el comprador:** Se deja fuera por seguridad; el mapa real → seudónimo vive solo en `state/` del servidor para mantener consistencia en vivo.
- **Contenido de los adjuntos (OCR):** Fuera porque el contrato solo entrega y exige `filename`; el nombre del archivo sí se anonimiza como texto.

2. ARQUITECTURA Y TRADE-OFFS (COMPONENTES, ALTERNATIVAS DESCARTADAS Y POR QUÉ)

Componente	Decisión Elegida	Alternativa Descartada	Por qué se descartó (Justificación Técnica)
Detección y Render (`known.py`, `llm.py`, `render.py`)	Aho-Corasick + Regex primero; el LLM solo devuelve spans JSON tipados y el código reemplaza con estilo espejo.	Pasar el texto completo al LLM para que lo reescriba o usar el LLM para detectar todo desde cero.	Reescribir inventa o borra datos de negocio y pierde parecido con la salida ideal, que reemplaza en lugar de redactar. Conocidos + regex atrapa de forma determinista y gratis lo que ya está en el padrón; según el enunciado, una solución por reglas llega a ~88 puntos, así que el LLM queda para terceros, apodos y casos ambiguos. Detectar solo el 70 % de las personas da 76: el recall manda.
Resolución de Entidades (`registry.py`, `resolve.py`)	Seudónimo anclado al `canonical_id` cruzando las 4 tablas maestras + ID global `external:` para terceros.	Diccionario plano `nombre → seudónimo` o resolver únicamente por el campo `user` (autor del mensaje).	Un mapa por nombre fusiona a las dos clientas homónimas y a la agente homónima de una clienta. Resolver solo por autor falla porque el bot menciona al agente en el traspaso y los agentes repiten correos y celulares de clientes.
Generador de Seudónimos (`pseudonym.py`)	`Faker(es_CO)` sembrado con `HMAC(secret, canonical_id)` sobre un mapa persistido: las personas existentes conservan su seudónimo y las colisiones solo afectan a las nuevas.	SHA-256, `[REDACTED]`, un seudónimo por género, cambiar 1 letra o dígito, o pedir al LLM que invente nombres.	Puntajes medidos en el enunciado: hashear da 58 (la cédula se revierte por fuerza bruta), `[REDACTED]` da 56 (destruye quién habló con quién), un seudónimo por género da 70 (fusiona a 150 personas) y cambiar una letra o dígito da 41 (el barrido global lo cuenta como fuga). El LLM inventando nombres rompe la consistencia en vivo.
Cuasi-Identificadores (`quasi.py`)	Solo cuando la tupla señala a una sola persona: ocupación a sector, barrio a ciudad y año a expresión, tanto en `clientes.csv` como en chats y documentos.	Desplazar el año al azar, borrar las columnas o generalizar únicamente dentro del texto del chat.	Desplazar un año único sigue dejando una fila única ($k = 1$); borrar columnas viola el esquema 1-a-1; aplicarlo solo en el chat deja expuesta la fila en `clientes.csv`, y la indirecta se evalúa sobre la unión.
Guard y Diccionario (`guard.py`, `exporter.py`)	Port de `contiene()` de `validar.mjs` + poda de `entities.json` a atributos usados, con el validador como compuerta dentro de `/v1/run`.	Guard basado solo en regex/entropía, exportar todos los atributos sintéticos, o validar solo a mano antes de la corrida.	Regex/entropía no ve nombres sin tildes ni dígitos con separadores raros. Un seudónimo declarado que no aparece en sus `records` hace fallar `validar.mjs`, y una salida inválida gasta la corrida sin puntaje. Durante una corrida oficial el jurado regenera la salida en nuestro servicio, así que la compuerta tiene que correr ahí.
Servicio y Crecimiento (`main.py`, `jobs.py`)	`/v1/run` asíncrono en un proceso aparte, ledger en disco persistente y `/anonymize` con corte a 45 s y respaldo determinista.	`/run` síncrono, seudónimos regenerados en cada corrida o esperar al LLM sin límite.	Si `/health` deja de responder durante una corrida, se pierde. Regenerar seudónimos rompe la comparación antes/después del crecimiento, que multiplica los puntos de consistencia. Esperar al LLM arriesga el límite de 60 s por lote de 50.

3. PLAN PARA MEDIR (CASOS DE PRUEBA PRE-CONSTRUCCIÓN Y MÉTRICAS CONCRETAS DESDE EL DISEÑO)

Caso de Prueba de Diseño	Cómo Sabemos si Funciona Antes de Construir (Input → Resultado Esperado)	Métrica Concreta	Umbral de Aprobación
Test 1 Calibración en Muestra y Tests Públicos	Correr los 13 tests de `sample/` y los 5 de `tests_public.json`; comparar contra `sample/expected_output/` (forma, reemplazos, diccionario y parecido del texto no personal) y correr `node validar.mjs` sobre la muestra y sobre la salida completa.	`Validator_Errors`, `Sample_Pass_Rate`, `Public_Pass_Rate` & `Text_Similarity`	**0 errores** · **13/13** · **5/5** · parecido **≥ 98 %**
Test 2 Superficies Ofuscadas y Ocultas	Inyectar extracto en `MAYUSCULAS SIN TILDES`, correo con *"arroba/punto"*, confusables cirílicos, caracteres invisibles, PDF con `/Author`, HTML con `<!-- -->` y adjunto con nombre propio.	`Normalized_Leak_Count` (con `norm()` y `digitosEn()`)	**0 apariciones** de formas reales en cuerpo, metadata y filenames
Test 3 Homónimas y Relación `reporta a`	Dos clientas con igual nombre en chats distintos (una con `PQR-1`, otra con monto de `TX-2`) + agente homónima de una clienta + árbol de jefes en `empleados.xml`.	`Homonym_Collision_Rate` & `Hierarchy_Integrity`	Clientas homónimas → **2 seudónimos**; agente ≠ clienta (**0 fusiones**) y **100 %** vínculos `reporta a` válidos
Test 4 Colisión Apellido vs Lugar/Marca	Texto mixto con *"la señora Restrepo pagó en Bancolombia desde el Barrio Restrepo y Seguros Bolívar"*.	`False_Positive_Entity_Rate` & `Kept_Declaration`	Reemplaza solo a la persona; conserva banco/barrio/marca con `kept: true` (**≤ 2 % FP**)
Test 5 Cuasi-IDs + Estabilidad Incremental	1) Unificar fila `clientes.csv` + chat con `(barrio, ocupación, año)` única. 2) Re-correr `/v1/run` agregando registros nuevos y comparar `entities.json`.	`Unique_Quasi_Tuples`, `Idempotency_Rate` & `Batch50_p95`	**0 tuplas únicas** expuestas · **100 %** mismos seudónimos previos · **p95 < 15 s**
Test 6 Categoría del Seudónimo y Estructura	Generar seudónimos para todo el padrón; comparar las uniones `transacciones→clientes` y `pqrs→clientes` antes y después, y el grafo de participantes de cada hilo.	`Gender_Match`, `Format_Valid`, `Shared_Tokens_With_Original`, `Join_Preservation` & `Thread_Graph_Match`	**100 %** mismo género y formato válido · **0** nombres, apellidos o dígitos compartidos con el original · **100 %** uniones y grafos iguales
Test 7 Corrida 1 como Medición Real	Lanzar la corrida 1 en cuanto los Tests 1–6 pasen y antes del crecimiento de fuentes (vale el 30 %); mide el 60 % de los tests ocultos.	`Score_Run1` y fallas por dimensión	**≥ 88** (referencia del enunciado para una solución por reglas sin modelos)

Stack: Python 3.11 · FastAPI · pyahocorasick · Faker (es_CO) con HMAC · Ledger persistido · Caché determinista por contenido