DIAGRAMA DE ARQUITECTURA Y DECISIONES TÉCNICAS — PIPELINE KIPU PAY

Cada etapa documenta el flujo de datos, las compuertas lógicas de decisión y la alternativa técnica descartada

Dann Arenas · Systems Design

1. INGESTA & NORMALIZACIÓN

API Fuentes (/v1 + ETag)

Descarga a `state/raw/` verificando cada id contra `record_index` (8.297 hoy; crece sin aviso).

Parsers con Preservación de Claves

- `clientes.csv` (Latin-1, `;`) & `transacciones.csv` (UTF-8)
- `pqrs.xml` & `empleados.xml`
- 11 PDF (texto+meta), 6 HTML (`<!-- -->`), 9 MD.

◊ Compuerta de Crecimiento:

¿Creció `record_index`? → *Sí:* `[SOURCES_GROWN]`, se carga el ledger y se regenera todo | *No:* corrida normal.

DECISIÓN VS. DESCARTADO

Elegido: Caché local con ETag y mapa de offsets.
Descartado: Streaming sin estado ni offsets (rompe el formato original al reemplazar).

2. GRAFO DE IDENTIDAD

Padrón Canónico Dual

Crea un `canonical_id` por persona desde `clientes.csv` (CL-∗) y `empleados.xml` (KP-∗ + `users.json`).

Resolución Relacional Cruzada

Vincula radicados (PQR-∗), `fecha+monto` (TX-∗), UID Slack y jerarquía `"reporta a"`.

◊ ¿Nombre con Homonimia?

1 dueño: Asignación directa.
≥2 dueños (2 clientas / agente): Desempata por PQR, TX, UID o adjunto en el hilo.

DECISIÓN VS. DESCARTADO

Elegido: Indexar por `canonical_id` + ID global `external:`.
Descartado: Mapa por nombre o resolver solo por `author` (fusiona homónimas y falla en traspasos).

3. DETECCIÓN EN 3 CAPAS

1. Aho-Corasick + 2. Regex CO

Barrido O(N) sin tildes/MAYÚSCULAS, emails con *"arroba/punto"*, cédulas, placas, pasaportes y Slack `<@U...>`.

3. Extractor de Spans LLM (Cacheado)

Detecta terceros fuera de tablas, apodos y etiqueta entidades públicas (`kept: true`) en ES y EN.

◊ ¿Apellido = Lugar/Marca?

Con marcador de persona (*"Sra. Restrepo"*) → Seudonimiza.
Con marcador de lugar/org (*"Barrio Restrepo"*, *"Seguros Bolívar"*) → Conserva (`kept: true`).

DECISIÓN VS. DESCARTADO

Elegido: LLM devuelve solo JSON de spans; código reemplaza.
Descartado: LLM reescribiendo texto (altera negocio, no es determinista y pierde parecido con la salida ideal).

4. SEUDÓNIMOS & CUASI-IDS

Faker (es_CO) + HMAC + Ledger

Semilla `HMAC(secret, canonical_id:attr)` sobre el ledger persistido. Conserva género, formato espejo de cédula/placa y estilo MAYÚSCULAS/deletreado.

Generalizador Cuasi-Identificadores

Unifica tabla y chat: lleva ocupación a sector (*"periodista"* → *"profesional de medios"*), barrio a ciudad y año a frase.

◊ ¿Tupla (Barrio, Ocupación, Año) Única?

Única en la unión tabla + texto (k = 1): Generaliza en `clientes.csv` y en los textos de esa persona.
No única: Conserva valor.

DECISIÓN VS. DESCARTADO

Elegido: Seudónimo con formato espejo + generalización dual.
Descartado: SHA-256 (reversible, 58 pts), `[REDACTED]` (56 pts) o desplazar año al azar (sigue siendo único).

5. GUARD & API /V1

Guard Espejo de validar.mjs

Busca variantes con `norm()` (NFKC + confusables + NFD) y `digitosEn()` (sin separadores ni prefijo 57).

Poda Coherente de entities.json

Incluye en `pseudonyms` solo atributos presentes en los `records` de la entidad + lista `kept: true`.

◊ Compuerta Pre-Salida (dentro de /v1/run):

¿0 formas reales en salida y 0 errores en `validar.mjs`? → Publica `chats/docs/tables.jsonl` + `entities.json`.

DECISIÓN VS. DESCARTADO

Elegido: Diccionario de valores reales + poda por `records`.
Descartado: Guard de entropía ciega y exportar seudónimos no usados en los registros.

FLUJO UNIFICADO BATCH (POST /V1/RUN) Y TIEMPO REAL (POST /V1/ANONYMIZE < 60S / 50 REGISTROS)

Ambos endpoints ejecutan el mismo pipeline sobre `state/entity_ledger.json`. `/v1/run` corre en un proceso aparte para que `/health` siempre responda. Si un registro en vivo menciona a una clienta o empleada existente, reutiliza su seudónimo de `output/`; si contiene una persona nueva, genera un `canonical_id` determinista sin colisión; si el LLM supera 45 s en un lote, aplica degradación elegante al motor determinista + Guard.

INMUTABILIDAD ANTE CRECIMIENTO DEL API DE FUENTES

Cuando el API agrega canales, fechas, documentos o filas, el ledger se carga antes de asignar: las personas previas conservan exactamente su seudónimo y las colisiones solo afectan a las nuevas. `HMAC(PSEUDONYM_SECRET, canonical_id)` reproduce los seudónimos si el ledger se pierde.